

Clasificación de Señales Eco-Acústicas: un pipeline integral de Machine Learning

CS3061 Machine Learning – UTEC – Proyecto 2 (Grupo 8)

Junio 2026 · Repositorio: github.com/AlejandroMarceloCh/clasificacion-senales-ecoacusticas

1. Resumen Ejecutivo e Introducción al Espacio Vectorial

La identificación autónoma de especies a partir de su huella acústica es una herramienta clave para el biomonitorio de ecosistemas. Se aborda la clasificación supervisada de **5 especies** (2 anfibios y 3 aves) a partir de descriptores espectrales. El conjunto de entrenamiento contiene $N = 1906$ observaciones y el de prueba 477, ambos descritos por un vector de características $\mathbf{x} \in \mathbb{R}^{64}$ correspondiente a coeficientes *Mel-Frequency Cepstral* (`mel_0–mel_63`). La variable objetivo $y \in \{10, 12, 17, 18, 23\}$ presenta un **desbalance moderado de 2,0:1** (Fig. 1a). Tras el análisis de variables auxiliares se incorporó `songtype_id` (codificada *one-hot*), resultando en un espacio efectivo de 66 dimensiones.




Figura 1: (a) Distribución de clases con desbalance 2,0:1. (b) Multicolinealidad severa entre las 64 características MFCC (113 pares con $|r| > 0,9$), lo que motiva la reducción de dimensionalidad.

Decisiones de ingeniería de datos. Se excluyó `recording_id` por inducir fuga de información (el 26,9 % de los identificadores del conjunto de prueba aparecen en entrenamiento). Las características se estandarizaron con `StandardScaler` ajustado *únicamente* sobre el entrenamiento para evitar contaminación del conjunto de prueba. La arquitectura completa del pipeline se ilustra en la Fig. 2.

Arquitectura del pipeline de clasificacion eco-acustica




Figura 2: Arquitectura del pipeline: desde la ingesta del CSV hasta la política de inferencia con umbrales.

2. Exploración Geométrica y Reducción de Dimensionalidad

Se contrastó un método lineal (PCA) frente a dos de variedades múltiples (t-SNE y UMAP). El PCA reveló una estructura de baja dimensionalidad intrínseca: **7 componentes** explican el 90 % de la varianza y 11 alcanzan el 95 %, dominando la primera componente con el 53,4 % (Fig. 3). La Tabla 1 reporta los tiempos de ejecución:

PCA es tres órdenes de magnitud más rápido, mientras que t-SNE y UMAP, aplicados sobre una pre-reducción PCA(20), priorizan la preservación de la estructura local a un costo mayor.




Figura 3: (a) Varianza explicada por componente y acumulada. (b) Proyecciones 2D: las dos especies de anfibios tienden a separarse de las aves, pero persiste solapamiento intra-grupo.

Método	Tiempo (s)	Varianza retenida	Estructura preservada
PCA(2)	0.0012	67.1 %	Global
PCA(7)	0.0012	90.0 %	Global
t-SNE(2)	3.297	—	Local
UMAP(2)	8.069	—	Local + global

Cuadro 1: Comparación de métodos de reducción de dimensionalidad (sobre 1906 muestras).

3. Minería de Patrones y Estructuras de Clustering

Se compararon dos paradigmas: KMeans/GMM (centroide/probabilístico) y DBSCAN (densidad), operando sobre la proyección PCA(20). El número de grupos se eligió mediante el **Coefficiente de Silhouette** (Fig. 4), cuyo máximo se ubica en $k = 2$, sugiriendo que la partición no supervisada más nítida corresponde a la dicotomía *anfibios vs. aves* antes que a las 5 especies. DBSCAN, barriendo $\varepsilon \in \{2,5, 3,0, 3,5\}$, fragmentó el espacio con ruido decreciente (Tabla 2).




Figura 4: Selección de k por Silhouette para KMeans y GMM. El óptimo en $k = 2$ refleja la separación anfibio/ave.

ε	Clusters	% ruido	Silhouette
2.5	17	42.0 %	-0,155
3.0	18	26.7 %	-0,051
3.5	11	14.7 %	0,099

Cuadro 2: DBSCAN para distintos ε ($\text{min_samples} = 5$).

Hallazgo. El índice ARI entre el GMM de 5 componentes y las etiquetas reales es de apenas 0,051: el agrupamiento acústico no supervisado *no reconstruye la taxonomía*. Esto evidencia que la separación entre especies

cercanas exige información supervisada.

4. Arquitectura de Clasificación: MLP vs. Modelos de Ensamble

Se entrenó un Perceptrón Multicapa (MLP) frente a un modelo de ensamble por *gradient boosting* (XGBoost). Dada la naturaleza desbalanceada del problema, la métrica primaria es el **F1-Score macro** y la función de pérdida es la *Cross-Entropy ponderada por clase*:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^5 w_c y_{i,c} \log \hat{p}_{i,c}, \quad w_c = \frac{N}{5 n_c}. \quad (1)$$

La topología del MLP se detalla en la Tabla 3. Se validó con **StratifiedKfold** (5 particiones) y pesos de clase balanceados en ambos modelos.

Capa	Salida	Activación	Regularización
Linear	256	ReLU	BatchNorm + Dropout(0.3)
Linear	128	ReLU	BatchNorm + Dropout(0.3)
Linear	64	ReLU	BatchNorm + Dropout(0.3)
Linear	5	Softmax	—

Cuadro 3: Topología del MLP ($66 \rightarrow 256 \rightarrow 128 \rightarrow 64 \rightarrow 5$).

Regularización. Se evaluó empíricamente la *posición relativa* de Dropout y BatchNorm sobre las curvas de pérdida (Fig. 5a). La configuración sin regularización minimiza la pérdida de entrenamiento pero a costa de sobreajuste; las variantes regularizadas convergen a pérdidas mayores y mejor generalización.




Figura 5: (a) Impacto de la posición de Dropout/BatchNorm en la pérdida. (b)–(c) Matrices de confusión sobre el conjunto de prueba oficial para MLP y XGBoost; la confusión se concentra entre especies acústicamente cercanas.

Modelo	F1-macro (CV)	F1-macro (test oficial)	Latencia (ms/muestra)
MLP (PyTorch)	0,536	0,575	0,0009
XGBoost (ensamble)	0,489	0,536	0,0075

Cuadro 4: Comparación de modelos. El MLP supera al ensamble en F1-macro y latencia.

El MLP obtiene el mejor desempeño (F1-macro = 0,575 en prueba, Tabla 4), consistente con la dificultad intrínseca estimada en el análisis exploratorio. Las matrices de confusión (Fig. 5b–c) confirman que el error se concentra en pares de especies con solapamiento espectral, no en un sesgo hacia la clase mayoritaria.

5. Decisiones de Ingeniería y Mitigación de Riesgos

Trade-off costo–rendimiento. El MLP no solo iguala sino que supera al ensamble en calidad (+0,039 F1-macro) con una latencia 8× menor (0,0009 vs. 0,0075 ms/muestra), ampliamente dentro de cualquier SLA operativo. Se selecciona por tanto como modelo de despliegue.

Política de moderación por umbrales. Sobre el vector de probabilidades *softmax* se define una política de tres zonas (Fig. 6): **Verde** ($P \geq 0,85$, clasificación automática), **Amarilla** ($0,40 \leq P < 0,85$, derivación a auditoría humana) y **Roja** ($P < 0,40$, descarte por ruido). La distribución de cobertura medida es 24,5 % / 67,1 % / 8,4 % respectivamente; la zona verde alcanza una exactitud del 76,1 % pese al F1-macro global moderado. Descartar la zona roja eleva el F1-macro de 0,536 a 0,569, validando cuantitativamente el umbral inferior.




Figura 6: Distribución de confianza del modelo y zonas operativas de decisión.

Contribution Statement

Integrante	% Contrib.	Tareas encargadas
Alejandro Marcelo	100 %	EDA, preprocesamiento, reducción de dimensionalidad
José Guerrero	100 %	Clustering, métricas internas, redacción
París Herrera	100 %	Modelado MLP/XGBoost, experimentos de regularización
Leonardo Montoya	100 %	MLOps, umbrales, informe y repositorio

Cuadro 5: Matriz de coevaluación del equipo de desarrollo.